

T2A 音效生成评测 PoC

方法与证据报告 / Stable Audio Open 1.0

从测试集、盲听 Rubric、五层诊断到 Badcase 与研发反馈

正式测试集	人工执行	核心口径
40 Prompt × 5 seeds = 200	220 次盲听	人工裁决
10 秒 / 44.1 kHz / stereo	含 20 次隐藏重复	OVL / REL / 事件诊断

作者：杜明 | 版本：v1.0 | 数据口径：ratings_final_200_adjudicated.csv

项目目标、范围与责任边界

目标不是发布模型排名，而是证明：换一个模型或数据集，仍然能够设计、执行、审核并交付一套可复查的音频评测流程。

项目回答	项目不回答
设计可控 Prompt 与 fixed seed 测试 拆分整体质量、语义相关性与事件错误 连接人工、客观指标、CLAP、统计与 Badcase 将观察转成回归测试与研发反馈	不发布跨模型排名 不把客观指标或 CLAP 作为语义裁决替代 不推断模型内部根因 不把未运行的 FAD/JS 包装为已有结果

我负责

提出五层框架；主动引入 STFT/FFT、BS.1770 响度与人耳响度曲线方向；设计测试集；亲自完成 200 条正式样本听评、隐藏重复复测与最终 Badcase 决策；审核方法、结果与对外表述。

AI 辅助

资料总结、批处理和脚本执行、重复样本提取、统计与表格生成、交付物制作。人工听感、语义判断与最终裁决不由 AI 替代。

评测能力覆盖矩阵

矩阵是对已完成 40 条英文 Prompt 的事后字面审计，不是生成前预注册标签，也不回写正式评分数据。

类别	声源	数量	时序	空间	材质	强度	持续	技术
自然环境	6	1	3	2	4	4	5	6
动作拟音	6	2	3	0	6	3	4	6
武器战斗	6	2	6	3	3	5	2	6
机械科技	6	2	3	2	0	2	6	6
动物	5	4	2	2	0	2	4	5
魔法幻想	5	0	3	0	3	4	3	5
日常生活	6	2	5	0	3	1	4	6
合计	40	13	25	9	19	21	28	40

已覆盖：声源识别 40/40、持续结构 28/40、时序 25/40。当前缺口：空间仅 9/40；魔法类无显式数量测试；机械与动物类缺少明确材质属性测试。

测试集、数据治理与 Listening Protocol

正式样本、隐藏重复和盲听事件分开治理；听评顺序用于减少文本预期对 OVL 的提前影响。

阶段	执行口径
测试集	40 条原创英文 Prompt × 5 个 fixed seeds (42 / 123 / 456 / 789 / 1024)
音频	200 条正式样本；10 秒、44.1 kHz、stereo WAV、100 steps
盲化	使用 Blind ID 隐去 Prompt、seed 与类别；另加 20 条隐藏重复，共 220 次盲听
步骤 1	先隐藏 Prompt，只听音频并评 OVL；允许重复播放
步骤 2	显示英文 Prompt，重新播放并评 REL；英文为正式语义参照，中文只作辅助
步骤 3	复听后填写主/次事件、属性、时序、数量与主要 Badcase
步骤 4	结合完整听感与诊断记录最终人工决策

监听链路	环境与电平	会话管理
Adobe Audition → MOTU M4 → Beyerdynamic DT 770 PRO X	安静室内；固定系统音量；未做标准化声压 / SPL 校准	每批约 30 条 / 45 分钟；休息约 15 分钟；两天完成

未做 SPL 校准，因此不声明跨实验室、跨设备的绝对播放声压可比性；固定系统音量只用于减少同一评测流程内的非必要变化。

OVL / REL 评分锚点与最终决策

下列锚点来自项目实际使用的评分说明，不是为了网页完整而重新发明的规则。

OVL	锚点	定义
1	不可用	静音、严重噪声、破音或明显生成失败
2	较差	勉强可辨认，但伪影、断裂或不自然感严重
3	基本可用	存在瑕疵，但可作为生成音效使用
4	良好	自然、完整，只有轻微问题
5	优秀	接近可以直接用于项目

REL	锚点	定义
1	无关	核心声源错误或几乎没有对应关系
2	弱相关	只符合大类，核心事件模糊或缺失
3	核心匹配	核心事件正确，但属性、次数或顺序缺失
4	大部分匹配	核心事件清楚，大部分属性和关系正确
5	高度匹配	核心事件、音色、次数、顺序基本全部满足

决策边界说明

原项目没有一份预先成文、互斥的 pass / keep_as_badcase / needs_regeneration 自动阈值。对外材料只将当前 adjudicated 数据中的模式标为事后归纳；最终决策由人工复听给出。

五层诊断框架与客观指标边界

每一层回答不同问题；L5 的人工 OVL、REL 与事件级裁决是最终感知和语义结论。

层级	职责	代表检查
L1 文件	基本可用性	解码、采样率、时长、静音、削波、端点风险
L2 频率	频谱结构	STFT、centroid、rolloff、flatness、频段能量
L3 空间	声道与相位	L/R energy、声道相关性、phase risk、panning
L4 能量	响度与动态	LUFS、true peak、LRA、crest
L5 感知	使用质量与语义	人工 OVL / REL、事件级诊断、Badcase

L1：200/200 可解码；abrupt_cutoff HIGH=0, MEDIUM=4 (2%) 。

L2：librosa STFT, n_fft=2048、hop=512、Hann、center=True；low 20-250 Hz、mid 250-4000 Hz、high ≥4000 Hz。

CLAP：仅前 5 秒、mono、44.1→48 kHz；与人工 REL p=-0.007、与 OVL p=-0.015，当前工作流不设硬阈值。

审核后正式结果

整体质量较高，但文本语义符合度与整体音质不能互相替代。

OVL mean	REL mean	OVL □ REL	正式决策
4.245	3.460	ρ 0.372	48 / 138 / 14
SD 0.93 / median 5	SD 1.05 / median 3	95% CI [0.243, 0.486]	pass / keep / regenerate

人工决策	n	占比
pass	48	24.0%
keep_as_badcase	138	69.0%
needs_regeneration	14	7.0%

探索关联

Prompt 聚类 n=40。ratio_500ms_to_full vs OVL: $\rho=-0.5398$, 95% CI [-0.7292, -0.2776]; integrated_lufs vs OVL: $\rho=0.4423$, 95% CI [0.1303, 0.6864]。17 个客观指标 × OVL/REL，仅作探索性诊断，无阈值、无因果解释。

Prompt × seed 稳定性与 Badcase

Prompt 内标准差用于回答：同一指令在五个 fixed seed 上是否稳定，而不是只看类别均值。

REL SD 排名	REL Mean	REL SD	主要观察
MEC_005	4.2	1.789	方向要求在 seed 间不稳定
FLY_006	2.4	1.342	布料摩擦的声源辨识波动
MEC_003	3.8	1.095	复合机械事件语义波动
WPN_001	3.8	1.095	枪声与尾部回声要求
ANI_002	4.0	1.0	多鸟声事件的 seed 波动

Badcase	n
wrong_count	39
wrong_attribute	34
missing_secondary_event	32
wrong_source	16
abrupt_cutoff	13
artifact_noise	11
wrong_temporal_order	5
other	3
extra_event	2
none	45

连续纹理专项观察与评分锚点

连续纹理是对既有正式样本的事后探索性分组，不新增标签，也不进行模型内部归因。

样本	评分 / 决策	可观察结论
B0191 / DLY_004	OVL 5 / REL 5 / pass	倒水与陶瓷杯属性保持较高辨识度，作为对照
B0082 / NAT_003	OVL 3 / REL 3 / wrong_attribute	海浪核心事件可辨，但材质与运动属性存在偏差
B0032 / FLY_006	OVL 2 / REL 1 / wrong_source	布料与衣物摩擦的声源和质感难以确认

评分锚点	样本	解释
OVL 5 / REL 5	B0008 / MEC_006	整体质量与核心事件均满足
OVL 4 / REL 1	B0152 / MEC_005	音质较好，但 Prompt 要求左→右，人工听感为右→左
OVL 1 / REL 1	B0092 / NAT_006	目标风吹竹林声源未确认；输出几乎均为难以辨认的杂音

观察：部分雨、海浪、风与布料摩擦输出呈现相似的宽带噪声质感，具体声源、材质或运动方式辨识度不足；仍需受控专项测试验证。

同一评测人复测、最终决策与版本追溯

20 对隐藏重复中，主要口径仅纳入评价顺序间隔 ≥ 30 的 15 对；结果不是多人一致性。

指标	结果
OVL exact	11/15 (73%)
OVL within-one	14/15 (93%)
REL exact	10/15 (67%)
REL within-one	15/15 (100%)
Badcase 标签一致	8/15 (53%)
人工决策一致	12/15 (80%)

B0092 / NAT_006_S0042 | 最终决策记录

“无法辨别，几乎都是杂音。” / “无法辨认，杂音过大。”

OVL 1、REL 1、technical_pass 否、artifact_severity 2、primary_event 0、attribute_match 0、wrong_source、needs_regeneration。该行 adjudication_applied=False，因此是封版数据中的最终决策示例，不是一次审核修改记录。

研发反馈示例 | WPN_004

把“听起来不对”转成可复查、可复现、可回归验证的问题描述。

字段	内容
问题类型	wrong_count / missing_secondary_event
影响维度	REL / 事件数量与事件结构
Prompt	Two swords clashing ... then one sword falling and clattering on stone ground
复现	5/5 seed 均有事件结构问题；3 条 wrong_count, 2 条 missing_secondary_event
代表样本	B0099: 第 1、3 次 impact 后出现杂音；主次事件相似、难区分，且数量过多
决策	5/5 keep_as_badcase; 用于专项分析与回归测试

建议回归测试

- 1. 单次与双次事件对照。
- 2. 增加碰撞与落地间隔。
- 3. 控制事件数量和背景干扰。
- 4. 固定 Prompt × seeds 复测，而不是只复现单条。

数据 QA: B0099 的 primary_badcase=wrong_count, 但 count_match=NA; 保留 canonical 值并进入字段一致性复核，不静默修正，也不据此推断内部机制。

限制、下一阶段与公开交付物

未完成工作只放在下一阶段，不改变现有 200 条正式结论。

状态	事项	边界
NOT RUN	完整七类 FAD / JS	weapon_combat 与 magic_fantasy 缺少类别匹配、许可明确、预处理可追溯的参考集
DESIGNED	36 条 Stress Set	count / temporal / source confusion 各 12 条；尚未生成 180 条音频，也未听评
NEXT	多评测员小规模校准	当前只有同一评测人复测，不能报告 ICC 或多人一致性
NEXT	第二模型或版本 A/B	在同一子集复用 Blind ID、Rubric 与回归流程

公开材料	用途
本方法与证据 PDF	快速理解完整方法链与边界
证据工作簿 XLSX	检查矩阵、Rubric、Prompt × seed、Badcase 和字段示例
Rubric / Protocol Markdown	复核真实评分锚点与听评操作规范
Data Dictionary + 10-row CSV	理解 Blind ID、Prompt、seed、评分和诊断字段
B0092 决策记录 + WPN_004 研发反馈	从单条样本追到最终决策与下一轮测试
作品集 PPT v1.4	3 分钟面试讲解与 C01-C04 试听

未公开 200 条原始生成音频或 1,640 条参考 WAV。所有统计继续以 adjudicated CSV 为唯一正式数据源。